

Informe breve - Retrieval v1

Data/IA -> Equipo de Agentes | NuevaMente

Objetivo: compartir los hallazgos de la evaluación del retrieval v1 y orientar la siguiente iteración sin modificar el Ground Truth ni el conjunto de 50 preguntas.

Resumen ejecutivo

Se evaluaron 50 casos del Ground Truth con el retrieval real entregado por Agentes. Tras una revisión manual del Ground Truth se ampliaron tres casos con múltiples chunks válidos. Con el Ground Truth corregido, quedaron **11 casos críticos reales**, definidos como aquellos con Recall@5 = 0.

Causa raíz	Casos
AMBIGUEDAD_CONTEXTO	4
RANKING_SEMANTICO	3
COMPETENCIA_INTRADOCUMENTO	2
ENTIDAD_LEXICAL	1
PREGUNTA_INFERENCIAL	1

Principales hallazgos

- **Ambigüedad de contexto:** preguntas genéricas sobre conocimientos previos, requisitos o ejercicios compiten con contenido similar de otros documentos.
- **Ranking semántico:** en varios casos existe contenido relacionado, pero el chunk relevante queda desplazado por otros chunks semánticamente cercanos.
- **Competencia intradocumento:** especialmente en Frontend y Cloud/DevOps, varios chunks del mismo documento compiten entre sí.
- **Entidades lexicales:** términos exactos como nombres de archivo, comandos o tokens técnicos pueden perderse en una búsqueda exclusivamente vectorial.
- **Preguntas inferenciales:** algunas consultas negativas o indirectas tienen poca coincidencia textual con la evidencia.

Métricas de referencia v1

Métrica	Baseline v1
Recall@3	0.5733
Recall@5	0.7533
Precision@3	0.2133
Precision@5	0.1640

Recomendaciones para Retrieval v2

1. **Contextualización / filtros por metadata.** Cuando exista información de document_id o categoría, usarla para reducir competencia entre documentos ante consultas ambiguas.
2. **Retrieval híbrido.** Combinar similitud vectorial con BM25 o búsqueda lexical para reforzar nombres de archivo, comandos, código y términos técnicos exactos.
3. **Reranking del Top-K.** Añadir una segunda etapa de ranking para reordenar chunks semánticamente cercanos y elevar la evidencia más específica.

Criterio experimental para v2

Para que la comparación sea válida, Data/IA recomienda mantener **exactamente las mismas 50 preguntas y el mismo Ground Truth** durante la prueba de Retrieval v2. De esta forma, cualquier cambio en las métricas puede atribuirse al retrieval y no a una modificación del conjunto de evaluación.

Objetivos de comparación

- Comparar Recall@3, Recall@5, Precision@3 y Precision@5 contra el baseline v1.
- Medir cuántos de los 11 casos críticos dejan de tener Recall@5 = 0.
- Revisar si mejoran los casos de ranking sin degradar categorías que ya muestran buen desempeño.
- Mantener trazabilidad de los cambios aplicados por Agentes para identificar qué intervención genera cada mejora.

Archivos de soporte

- retrieval_error_analysis_v1.csv
- retrieval_root_cause_summary_v1.csv
- retrieval_root_cause_by_category_v1.csv

Conclusión: el retrieval v1 ya cuenta con una línea base reproducible y un diagnóstico de causa raíz. La siguiente iteración debería enfocarse en contexto, búsqueda híbrida y reranking, manteniendo fijo el conjunto de evaluación.