

Informe de evaluacion - Retrieval v1

Trazabilidad de Ground Truth v1 vs Ground Truth v2 | Data/IA - NuevaMente

Objetivo: documentar de forma reproducible la evaluacion del mismo batch de Retrieval v1 contra dos versiones del Ground Truth. Ground Truth v1 se conserva como referencia congelada y Ground Truth v2 incorpora tres ajustes manuales de relevancia sin modificar el retrieval.

Resumen ejecutivo

Se evaluaron los mismos 50 casos del batch real entregado por el equipo de Agentes. La primera medicion reproduce el baseline con **Ground Truth v1**. La segunda usa **Ground Truth v2**, que reconoce chunks equivalentes validos en tres casos revisados manualmente. El retrieval utilizado es exactamente el mismo en ambas mediciones.

Evaluacion	Recall@3	Recall@5	Precision@3	Precision@5
Retrieval v1 + GT v1	0.5400	0.7200	0.1867	0.1480
Retrieval v1 + GT v2	0.5733	0.7533	0.2133	0.1640

Interpretacion: la diferencia entre ambas filas no representa una mejora del retrieval. El sistema de recuperacion no cambio; cambio la referencia de relevancia. GT v2 reduce falsos negativos al reconocer evidencia equivalente que GT v1 no contemplaba.

Versionado y reproducibilidad

Ground Truth v1 debe permanecer congelado junto con **evaluation_manifest_v1.json**. GT v2 se mantiene como una nueva referencia versionada, basada en el mismo corpus y los mismos chunks v1. Esto permite reproducir tanto el baseline original como la reevaluacion corregida.

Resultados con Ground Truth v2

Los 50 casos fueron procesados con status **success**. No se registraron errores tecnicos en el lote. Las metricas de GT v2 son las que se utilizaron para el analisis de errores y causas raiz.

Categoria	Recall@3	Recall@5	Precision@3	Precision@5
Backend	0.5167	0.7167	0.2333	0.1800
Cloud / DevOps	0.8000	0.8000	0.2667	0.1600
Data Science	0.6000	0.8000	0.2000	0.1600
Frontend	0.3500	0.5500	0.1333	0.1200
IA	0.6000	0.9000	0.2333	0.2000

Analisis de errores criticos

Con GT v2 se identificaron **11 casos criticos**, definidos como casos con Recall@5 = 0. El analisis manual agrupo esos casos en cinco tipos de causa raiz.

Causa raiz	Casos
AMBIGUEDAD_CONTEXTO	4
RANKING_SEMANTICO	3
COMPETENCIA_INTRADOCUMENTO	2
ENTIDAD_LEXICAL	1
PREGUNTA_INFERENCIAL	1

Principales hallazgos

Ambigüedad de contexto: consultas genericas sobre requisitos, conocimientos previos o ejercicios compiten con contenido similar de otros documentos.

Ranking semantico: se recupera contenido relacionado, pero el chunk relevante queda fuera del Top-5 o por debajo de otros chunks cercanos.

Competencia intradocumento: varios chunks del mismo documento contienen terminos relacionados y desplazan la evidencia mas especifica.

Entidad lexical: nombres exactos de archivo, comandos y tokens tecnicos pueden perderse con una busqueda exclusivamente vectorial.

Pregunta inferencial: consultas negativas o indirectas tienen poca coincidencia textual con la evidencia de origen.

Recomendaciones para la siguiente iteracion de retrieval

- 1. Contextualizacion y filtros por metadata.** usar document_id, categoria o informacion contextual disponible para reducir competencia entre documentos en consultas ambiguas.
- 2. Retrieval hibrido.** combinar similitud vectorial con BM25 o busqueda lexical para reforzar nombres de archivo, comandos, codigo y terminos tecnicos exactos.
- 3. Reranking del Top-K.** incorporar una segunda etapa de ranking que priorice la evidencia mas especifica entre resultados semanticamente cercanos.

Criterio experimental para Retrieval v2

Para evaluar una futura version del retrieval, se recomienda mantener fija una referencia de evaluacion durante el experimento. Si el equipo adopta GT v2 como referencia vigente, Retrieval v2 debera compararse contra **las mismas 50 preguntas y el mismo GT v2**. GT v1 se conserva como baseline historico congelado para trazabilidad.

Objetivos de comparacion

- Comparar Recall@3, Recall@5, Precision@3 y Precision@5 contra el baseline definido para la referencia elegida.
- Medir cuantos de los 11 casos criticos dejan de tener Recall@5 = 0.
- Revisar si mejoran los casos de ranking sin degradar categorias con mejor desempeno.
- Mantener trazabilidad de cada cambio realizado por Agentes para atribuir correctamente las mejoras.

Archivos de soporte

- retrieval_metrics_gt_v1.csv
- retrieval_results_gt_v1.csv
- retrieval_category_summary_gt_v1.csv
- retrieval_status_summary_gt_v1.csv
- retrieval_metrics_gt_v2.csv
- retrieval_results_gt_v2.csv
- retrieval_category_summary_gt_v2.csv
- retrieval_status_summary_gt_v2.csv
- retrieval_error_analysis_gt_v2.csv
- retrieval_root_cause_summary_gt_v2.csv
- retrieval_root_cause_by_category_gt_v2.csv

Conclusion: el proyecto conserva ahora una linea base historica reproducible con GT v1 y una referencia revisada GT v2. La reevaluacion con GT v2 no representa una mejora del retrieval; refleja una definicion de relevancia mas completa. El diagnostico actual mantiene 11 casos criticos y orienta la siguiente iteracion hacia contexto, busqueda hibrida y reranking.